

ArXiv Warriors

Multimodale Informationspräsentation
in bioRxiv-Preprints

Abschlusspräsentation · DIS22 · TH Köln · 2026

Mogens Rosiny
Robin Klinkhammer
Cem İlhan Tozak

FORSCHUNGSFRAGE

In welchem Ausmaß überschneiden sich die Informationen in Tabellen mit dem umliegenden Fließtext in bioRxiv-Preprints?

Fokus: Methodik & Entwicklung des Projekts

3.810 Dokumente · 10.131 Tabellen ausgewertet

Agenda

01

Worum geht es?

Problem, Beispiel & wie wir messen

Mogens

02

Unser Verfahren

Die Entwicklung über alle Code-Versionen

Cem

03

Analyse & Ergebnisse

Was auf 3.810 Dokumenten herauskam

Robin

Das Problem: Information Overload

Mogens

WURUM GEHT ES?

Die Menge wissenschaftlicher Veröffentlichungen wächst ständig. Jede Arbeit kombiniert Text, Tabellen und Abbildungen.

Für Leser:innen stellt sich die Frage: Liefert eine Tabelle zusätzliche Information – oder wiederholt sie nur den Text?

Eigenständige Tabelle → erhöht die Informationsdichte. Sinnvoll, kein Overload.

Redundante Tabelle → erzeugt kognitive Last ohne Mehrwert.

FORSCHUNGSFRAGE

In welchem Ausmaß überschneiden sich die Informationen in Tabellen mit dem umliegenden Fließtext in bioRxiv-Preprints?

Gleicher Tabellenwert – zwei völlig verschiedene Behandlungen im Text.

In der Tabelle:

Accuracy = 92,3 %

A Überschneidung

„...das Modell erreichte 92,3 % Genauigkeit.“

B keine Überschneidung

„...Ergebnisse siehe Tabelle 1.“

Wie wir messen: der Overlap-Score

Mogens

1

Referenz finden

Stelle im Text, z. B. „see Table 2“

2

Textfenster

±500 Zeichen um die Referenz

3

Zahlen extrahieren


aus Tabelle und Textfenster

4

Score berechnen

Anteil gemeinsamer Zahlen

0 = eigenständig · 1 = komplett wiederholt



Overlap = übereinstimmende Zahlen ÷ Tabellenzahlen (0 – 1)

Score-Verteilung: die meisten Tabellen liegen nahe 0 – wenig Überschneidung.

Die 4 Kategorien

Mogens

info_in_text

„...erreichte 92,3 %.“

Werte stehen explizit im Text

partial

„...wie in Tabelle 2 gezeigt, steigt die Leistung.“

beschrieben, aber ohne Zahlen

only_table

„Ergebnisse siehe Tabelle 1.“

nur ein Verweis, kein Inhalt

no_refs

(kein Verweis im Text)

gar nicht erwähnt

Wichtig: Overlap-Score $\neq$ Klassifizierung

Mogens

Overlap-Score

unsere eigentliche Messung

kontinuierlich, 0–1

→ **beantwortet die Forschungsfrage**

Klassifizierung (4 Labels)

nur ein Kontroll-Werkzeug


vergibt unser Verfahren die Kategorien wie ein Mensch?

→ **beantwortet: funktioniert unser Verfahren?**

„Wie viel Überschneidung gibt es“ $\neq$ „Wie zuverlässig misst unser Code das“ — diese Kontrolle hat unseren ganzen weiteren Weg bestimmt.

Unser Verfahren & der Weg dahin

Cem



499 Testdokumente → 3.810 echte Dokumente (10.131 Tabellen)



Lange nur Testdaten – die echten Daten kamen erst ganz am Ende. Alles davor war Vorbereitung.

Phase 0 – Erster Prototyp (Zwischenstand)

Cem

AUFBAU

- Textfenster ± 500 Zeichen
- nur Dezimalzahlen verglichen
- keine Tabellen-Unterscheidung
- keine Klassifizierung, keine Kaskade
- alle 3 Methoden auf alle Paper

Regex $\approx$ spaCy

konsistente Werte, Korrelation $r = 0,74$

→ vertrauenswürdige Baseline

LLM unbrauchbar

72 % der Scores exakt 0,8

→ Halluzination, kein Messwert

Phase 1 – Labelverteilung des Prototypen

Kategorisierungsanalyse · n = 386 Tabellen

37%

only_table

Tabelle wird im Fließtext
gar nicht referenziert

Kein In-Text-Verweis

54%

partial

Nur oberflächliche Erwähnung
(z.B. 'siehe Tab. 1')

Formaler Verweis ohne Inhalt

8%

info_in_text

Tabelleninhalt wird
inhaltlich erklärt

Echter informativer Bezug

Nur 8% der Tabellen werden inhaltlich erklärt – 91% sind eigenständig oder nur formal referenziert.

Phase 1 – Manuelle Annotation

Kategorisierungsanalyse · n = 386 Tabellen

33%

only_table

Tabelle wird im Fließtext
gar nicht referenziert

Kein In-Text-Verweis

53%

partial

Nur oberflächliche Erwähnung
(z.B. 'siehe Tab. 1')

Formaler Verweis ohne Inhalt

12%

info_in_text

Tabelleninhalt wird
inhaltlich erklärt

Echter informativer Bezug

Nur 12% der Tabellen werden inhaltlich erklärt – 88% sind eigenständig oder nur formal referenziert.

Phase 2a – improved_pipeline


Cem

- Kaskade Regex → spaCy → LLM
- handgesetzte Schwellenwerte
- Fenster nur vorwärts (500)
- Matching über fehlerhaften Zähler

$\kappa = 0,269$

schlechter als die Regex-Baseline ($\kappa = 0,33$)

Lektion: geratene Regeln reichen nicht – wir brauchen ein datengetriebenes Verfahren.



Phase 2b – optimized_pipeline: die Overfitting-Falle

Cem

Behoben gegenüber 2a:

- Random Forest statt Hand-Schwellen
- Matching über DOI + Tabellename
- bidirektionales Fenster ± 1000
- ref_wc als Feature ergänzt


ehrlich (CV)

$\kappa = 0,426$
minimal besser

Test = Training

$\kappa = 0,857$
Overfitting!

Falle: auf denselben 386 Tabellen trainiert UND getestet. Eigentliches Problem: zu wenig Daten für ein stabiles Modell.



pipeline_v3_cascade

99,1 %

Accuracy ($\kappa = 0,987$)

Warum so „perfekt“?

- Die 5-Fold-Kreuzvalidierung lief über zufällige Gruppen – nicht über Dokumente.
- Dadurch landeten Tabellen desselben Papers gleichzeitig in Training und Test.
- Das Modell kannte die Antworten schon → Datenleck.
- Wir hatten viel geändert, aber den Split noch nicht sauber.

→ Der Moment, an dem wir grundsätzlich umgedacht haben.

Phase 3b – Die Lösung: regelbasierte Kaskade

Cem

Entscheidung: kein trainiertes ML-Modell mehr – zurück zu einem transparenten, regelbasierten Verfahren.

Kaskade Regex → spaCy

**Schwellen je
Tabellengröße**

**Split auf Dokument-
Ebene**

LLM komplett entfernt

Bewertung nicht über eine fragile Kreuzvalidierung, sondern über die Frage: liefert das Verfahren auf ungesehenen Dokumenten dieselben Ergebnisse?

Was wir strukturell verändert haben

Cem

Stellschraube	Entwicklung	Ergebnis
Textfenster	beidseitig → nur vorwärts → wieder beidseitig (± 1000)	✓ realistischer
Zahlen vs. Wörter	nur Dezimalzahlen → + Keyword-Matching für Text-Tabellen	✓ Text-Tabellen besser
Kategorisierung	keine → Größe + Inhaltstyp mit eigenen Schwellen	✓ Kernverbesserung
Modellansatz	Hand-Schwellen → Random Forest → regelbasierte Kaskade	✓ stabil & klar
Matching	über idx (fehlerhaft) → über DOI + Tabellename	✓ 100 % korrekt
Evaluierung	Test = Training / zufällige CV → Split auf Dokument-Ebene	✓ ehrlich
LLM	im Prototyp aktiv → später Stufe weg → final deaktiviert	X raus

Wie die finale Kaskade genau arbeitet

Robin

ABLAUF

1

Regex – Overlap

Zahlenabgleich, bei Text-Tabellen Keyword-Matching

2

spaCy – NER + Dependency

Zahlen-Entitäten; nur Sätze mit Überschriften-Stichwort

3

Entscheidungsbaum

Label aus Overlap + Referenzlänge (ref_wc),
größenabhängig

kein LLM mehr

Tabellen-Unterscheidung

Größe (Zellenzahl)

klein ≤ 12 · mittel 13–50 · groß > 50

Inhaltstyp (Zahlenanteil)

numerisch $\geq 0,70$ · Text $\leq 0,20$ · sonst mixed

Schwellen je Größe

große Tabellen brauchen weniger relativen
Overlap

3.810

Dokumente

10.131

Tabellen


3.048 / 762

Train / Test (Dokumente)

Split auf Dokument-Ebene (80/20). Alle Tabellen eines Papers bleiben zusammen – nie gemischt zwischen Train und Test. Genau das verhindert das Datenleck von vorher und macht die Ergebnisse ehrlich.

Kernergebnis: Wie werden Tabellen behandelt?

Robin




≈ 53 %

der Tabellen (only_table + no_refs)
werden im Text inhaltlich nicht
aufgegriffen.

**Tabellen sind überwiegend
eigenständige Informationsquellen.**

Robustheit: generalisiert das Verfahren?

Robin



So getestet



Vergleich der Label-Verteilung zwischen Train- und Test-Dokumenten.

Alle Labels weichen < 2 % ab.

→ kein Auswendiglernen, sondern ein echtes, übertragbares Muster.

Vertiefung: Größe, Inhaltstyp & Methoden

Robin



Größe: kleine Tabellen kaum Overlap, mittlere am stärksten verzahnt. **Typ:** numerisch → spaCy besser, Text → Regex besser (Keyword-Matching). **Gesamt:** Ø Overlap nur ~14–16 %.

Fazit

- Tabellen überwiegend eigenständig (~53 % nicht abgedeckt)
- robustes, interpretierbares Verfahren
- generalisiert (< 2 % Train/Test)

Limitationen

- kein Ground Truth auf den 10.131 echten Tabellen
- Schwellenwerte plausibel, aber gesetzt
- LLM nicht nutzbar gemacht

Ausblick

- Stichproben-Annotation der echten Daten
- Schwellen datengetrieben kalibrieren

Vielen Dank

Fragen?

Mogens Rosiny · Robin Klinkhammer · Cem İlhan Tozak